Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería de Transporte y Logística

ICT3115 – Sistemas Urbanos Inteligentes (I/2026)

Tarea 1

Descripción del problema

En esta Tarea 1, practicará elementos centrales para el desarrollo de sistemas urbanos inteligentes basados en datos tabulares:

- La definición de una tarea predictivo en un contexto urbano.
- La recopilación, compilación y consolidación de una tabla de datos para el análisis.
- El entrenamiento y comparación de modelos neuronales para tareas predictivas con datos tabulares.
- El análisis de distintas estrategias de representación para variables numéricas, categóricas y geoespaciales.

Para lograr esto, deberá inicialmente definir un problema de interés dentro de los que pueden ser enfrentados por los sistemas urbanos inteligentes, y luego buscar uno o más conjuntos de datos que permitan capturar la información relevante para el problema. A continuación, deberá consolidar la información en una única tabla final, evaluar distintos esquemas de representación y entrenar modelos neuronales que permitan resolver el problema elegido.
El objetivo de la tarea no es maximizar el rendimiento predictivo, sino estudiar cómo distintas decisiones de representación y modelamiento afectan el aprendizaje y el comportamiento de los modelos.

Sobre el foco de la tarea

En esta tarea, el foco principal no está en obtener el mejor rendimiento predictivo posible, sino en lograr que los modelos aprendan y en analizar críticamente dicho aprendizaje.

Por esta razón, la tarea no será evaluada en función del mejor resultado numérico alcanzado, ni tampoco se espera que cada variante de modelo supere necesariamente a las anteriores. De hecho, es perfectamente posible que un modelo más simple, como el MLP base, obtenga el mejor rendimiento final.
Lo central en esta tarea es que usted diseñe comparaciones razonables entre distintas estrategias de representación y modelamiento, observe cuidadosamente el comportamiento de los modelos, y discuta de manera fundada por qué cree que obtuvo los resultados observados.

Sobre el problema a resolver

La temática del problema es libre, siempre que este cumpla simultáneamente las siguientes condiciones:

- Debe surgir en un contexto urbano o utilizar datos generados o derivados de entornos urbanos.
- Debe poder formularse como una tarea predictiva supervisada, ya sea de regresión o de clasificación.
- Debe considerar una única variable objetivo principal, cuya elección deberá ser justificada claramente.

Sobre los datos

Deberá trabajar con una única tabla final consolidada, la cual puede ser construida a partir de una o más fuentes de datos.
Los datos deben cumplir las siguientes condiciones:

- Formato tabular, sin límite en la cantidad de columnas.
- Existencia de características (variables independientes) numéricas reales.
- Existencia de características (variables independientes) categóricas y/o ordinales.
- Existencia de variables geoespaciales cuando estas sean relevantes para el problema.
- Existencia de una variable objetivo principal, la cual puede ser numérica o categórica/ordinal.

En esta tarea, las variables geoespaciales merecen atención especial. En muchos problemas urbanos, la localización exacta no necesariamente constituye la representación más adecuada de la información espacial relevante para la predicción. Dependiendo del problema, puede resultar conveniente representar la información geoespacial mediante coordenadas continuas, mediante una discretización espacial seguida del uso de embeddings, o mediante una combinación de ambas estrategias. En consecuencia, si su conjunto de

datos contiene variables geoespaciales relevantes, deberá incorporarlas explícitamente y justificar cómo las representa.

Se valorará especialmente que la selección de datos sea pertinente para el problema y no simplemente conveniente desde el punto de vista técnico.

Finalmente, considere el uso de subconjuntos relevantes de los datos en caso de que los tiempos de ejecución se vuelvan prohibitivos, siempre que dicha decisión esté debidamente justificada y no comprometa la validez de la evaluación experimental.

Algunos sitios que puede visitar para buscar conjuntos de datos son los siguientes: Awesome Urban Datasets, Kaggle, Awesome Urban Foundation Models. Adicionalmente, si nunca ha utilizado datos urbanos y/o geoespaciales en Python, se recomienda revisar el material complementario en el sitio del curso.

Sobre los modelos

Deberá utilizar modelos de redes neuronales profundas afines a datos tabulares, como los descritos hasta ahora en el curso y en las lecturas. En particular, la tarea se centra en arquitecturas de tipo MLP, embeddings para variables discretas y AutoEncoders para aprendizaje de representaciones.

Puede basarse en ideas, artículos, repositorios o tutoriales existentes, siempre que se cumplan simultáneamente las siguientes condiciones:

- El código entregado haya sido efectivamente escrito o modificado por usted.
- Comprenda íntegramente lo implementado.
- Justifique las decisiones metodológicas adoptadas.
- Cite adecuadamente cualquier fuente externa utilizada.

Actividades a realizar

A continuación se detallan las actividades que deben ser desarrolladas en esta tarea:

1. **Definición del problema y preparación de los datos.** Debe definir el problema urbano a resolver, justificar la variable objetivo seleccionada y construir una única tabla final para el análisis. Luego deberá realizar los procedimientos de preprocesamiento que considere adecuados, por ejemplo limpieza, imputación de valores faltantes, transformación de variables, normalización, codificación de categorías, discretización espacial u otras operaciones pertinentes. Además, deberá definir explícitamente una partición en conjuntos de entrenamiento, validación y prueba, justificando brevemente su estrategia.

2. **Entrenamiento de un modelo base con MLP simple.** Debe entrenar un modelo predictivo base utilizando una arquitectura MLP sencilla, sin embeddings para ninguna variable. En este paso deberá explicar cómo representó las variables no numéricas y qué limitaciones observa en dicha representación.

3. **Entrenamiento de un modelo MLP con embeddings.** Debe entrenar un modelo MLP que incorpore embeddings para las variables que no sean numéricas reales y cuya representación discreta resulte razonable. Esto incluye variables categóricas, ordinales y, cuando corresponda, variables geoespaciales discretizadas. En este paso deberá justificar qué variables fueron representadas mediante embeddings, justificar en el caso geoespacial si utilizó coordenadas continuas, discretización con embeddings, o ambas, visualizar y analizar al menos uno de los espacios de embeddings aprendidos, y comparar el comportamiento del modelo respecto del modelo base, tanto en términos de desempeño como de generalización.

4. **Análisis del sobreajuste y regularización.** Sobre al menos uno de los modelos anteriores, deberá analizar explícitamente la existencia de sobreajuste utilizando los conjuntos de entrenamiento y validación. Además, deberá incorporar al menos una estrategia de regularización, por ejemplo, dropout, early stopping, penalización L_2 (*weight decay*) u otra comparable, y discutir su efecto sobre el desempeño y la generalización.

5. **Aprendizaje de representaciones mediante AutoEncoder.** Debe entrenar primero un modelo de tipo AutoEncoder sobre las variables de entrada. Una vez entrenado, deberá utilizar la representación generada por el encoder, es decir, el cuello de botella, para entrenar un MLP simple que resuelva la tarea predictiva principal. En esta etapa deberá justificar la arquitectura del AutoEncoder, considerar si resulta conveniente incorporar o no embeddings dentro de este esquema, y discutir cómo cambia el comportamiento del modelo al utilizar esta representación alternativa, independientemente de si ello mejora o no el rendimiento final. Como referencia e inspiración para este ítem, puede considerar el artículo *Deep Architecture for Citywide Travel Time Estimation Incorporating Contextual Information*, disponible en las lecturas del curso.

6. **Análisis crítico final.** Debe cerrar la tarea realizando un análisis crítico de los resultados obtenidos. Este análisis debe incluir, al menos, una comparación entre las distintas estrategias de representación utilizadas, una discusión sobre el papel de las variables categóricas y geoespaciales, un análisis del efecto de la regularización, las principales dificultades encontradas, y conclusiones sobre la pertinencia de los enfoques utilizados para el problema elegido.

Evaluación experimental

La evaluación debe ser consistente con la naturaleza de la variable objetivo elegida.

- Si su tarea es de clasificación, deberá utilizar métricas adecuadas tales como accuracy, balanced accuracy cuando corresponda, matriz de confusión, precision, recall y F1-score.
- Si su tarea es de regresión, deberá utilizar métricas adecuadas tales como MAE, MAPE, RMSE y, cuando resulte pertinente, R^2.

En todos los casos, debe distinguir claramente entre resultados obtenidos en entrenamiento, validación y prueba. El conjunto de prueba debe utilizarse exclusivamente para la evaluación final de los modelos seleccionados.

Criterios de evaluación

La corrección de la tarea se realizará de manera cualitativa, considerando principalmente los siguientes aspectos:

- La pertinencia del problema urbano planteado y la claridad con que este es formulado.
- La calidad del proceso de preparación, consolidación y representación de los datos.
- La corrección técnica de la implementación de los modelos solicitados.
- La calidad del diseño experimental, incluyendo la comparación entre distintas estrategias de representación y modelamiento.
- La profundidad del análisis realizado sobre el aprendizaje, la generalización, el sobreajuste y el comportamiento de los modelos.
- La capacidad de discutir y justificar los resultados obtenidos, incluso cuando estos no impliquen mejoras de rendimiento.
- La claridad, orden y reproducibilidad del notebook entregado.

No se evaluará la tarea en función del mejor rendimiento predictivo bruto alcanzado, sino en función de la calidad del proceso experimental, de la pertinencia de las comparaciones realizadas y del análisis crítico desarrollado a partir de los resultados obtenidos.

Desarrollo y entrega

La tarea debe desarrollarse utilizando PyTorch, Keras u otro framework equivalente. Se recomienda utilizar Google Colab u otra plataforma similar que facilite la instalación de librerías y el entrenamiento de modelos. La entrega debe realizarse mediante un archivo `.ipynb`, que contenga tanto código como explicaciones y comentarios, incluyendo la salida de todas las celdas ejecutadas. Se recomienda no incluir en la entrega los archivos de datos utilizados, a menos que ello sea inevitable.
Además del código, el notebook debe permitir identificar con claridad los siguientes elementos:

- El problema definido.
- El origen y estructura de los datos.
- Las decisiones de preprocesamiento y representación.
- La configuración de cada modelo entrenado.
- La comparación de resultados.
- Las conclusiones finales.

La fecha límite de entrega es el sábado 18 de abril a las 23:59, a través del buzón que se habilitará en el sitio del curso. Para fines de corrección, se revisará la última versión entregada.

Política de Integridad Académica

Los/as estudiantes de la Escuela de Ingeniería de la Pontificia Universidad Católica de Chile deben mantener un comportamiento acorde a la Declaración de Principios de la Universidad. En particular, se espera que mantengan altos estándares de honestidad académica. Cualquier acto deshonesto o fraude académico está prohibido; los/as estudiantes que incurran en este tipo de acciones se exponen a un Procedimiento Sumario. Es responsabilidad de cada estudiante conocer y respetar el documento sobre Integridad Académica publicado por la Dirección de Docencia de la Escuela de Ingeniería.

Todo trabajo presentado por un/a estudiante para los efectos de la evaluación de un curso debe ser hecho por el/la estudiante. El/la estudiante es **responsable de originar el material entregado y de conocer íntegramente su contenido**. Asimismo, deberá respetar estrictamente las condiciones definidas por el curso para cada trabajo (por ejemplo, si el trabajo es individual, grupal, y si se permite o no el uso de material digital o de asistentes de inteligencia artificial). Por "trabajo" se entiende en general las interrogaciones escritas, las tareas de programación u otras, los trabajos de laboratorio, los proyectos, el examen, entre otros.

Si un/a estudiante incurre en una falta a la integridad académica, como, por ejemplo, entregando trabajo que no es propio, no comprendiendo íntegramente el trabajo entregado, o no cumpliendo con las condiciones establecidas por el curso, obtendrá nota final 1.1 en el curso y se solicitará a la Dirección de Pregrado de la Escuela de Ingeniería que no le permita retirar el curso de la carga académica semestral. En todos los casos, se informará a la Comisión de Integridad Académica de la Escuela de Ingeniería para que tome sanciones adicionales si lo estima pertinente.

En caso de utilización de fuentes digitales como Wikipedia o el uso de asistentes inteligentes como ChatGPT o Copilot, cuando se permita su uso, debe declararse de forma explícita el material o herramienta usada. En caso de uso de asistentes de inteligencia artificial, el profesor/a del curso puede solicitar que se entreguen respaldos sobre su utilización (por ejemplo, historial o logs).

Lo anterior se entiende como complemento al Reglamento del Estudiante de la Pontificia Universidad Católica de Chile (`https://registrosacademicos.uc.cl/reglamentos/estudiantiles/`). Por ello, es posible pedir a la Universidad la aplicación de sanciones adicionales especificadas en dicho reglamento.

Compromiso del Código de Honor

Este curso suscribe el Código de Honor establecido por la Universidad, el que es vinculante. Todo trabajo evaluado en este curso debe ser propio. En caso que exista colaboración permitida con otros/as estudiantes, el

trabajo deberá referenciar y atribuir correctamente dicha contribución a quien corresponda. Como estudiante es un debe conocer el Código de Honor (`https://www.uc.cl/codigo-de-honor/`).